

# Relatório - Aula Prática 1

Gustavo Ramalho\*

27 de Março de 2022

## 1 Questão 1

Implementar uma função Scilab resolvendo um sistema linear  $Ax = b$  usando o algoritmo iterativo de Jacobi.

```
1 function [xk, normadif, nk, normares]=Jacobi(A,b,x0,E,M,tiponorma)
2
3     D = diag(diag(A));
4     LU = A-D;
5     invD = diag(1./diag(A));
6
7     Mj=invD*(LU);
8     Cj=invD*b;
9
10
11     xk = x0;
12     normadif = E;
13     nk = 0;
14     while normadif >= E && nk<M
15         x0=xk;
16         xk=-Mj*x0+Cj;
17         dif = x0 - xk;
18         normadif = norm(dif,tiponorma);
19         nk = nk+1;
20     end
21
22     normares=norm(A*xk-b,tiponorma);
23
24 endfunction
25
26
27
```

Dado esse código, é necessário definirmos o que representa cada variável de entrada e saída:

### Variáveis de entrada

- A: matriz A
- b: vetor b
- x0: vetor inicial utilizado
- E: tolerância
- M: Número máximo de iterações
- tiponorma: Tipo de norma a ser utilizado

---

\*gustavoramalho384@gmail.com

### Variáveis de saída

- xk: solução encontrada
- normadif: Norma da diferença entre as duas últimas aproximações
- normares: norma do resíduo
- nk: número k de iterações efetuadas

Como vimos em aula, transformei  $Ax = b$  em  $(L + D + U)x = b$ , e, nesse sentido, fui fazendo as operações até poder chamar  $D^{-1} \cdot LU$  de  $M_j$  e  $D^{-1} \cdot b$  de  $C_j$  (tudo sem usar a função inv). Depois, usei o while para fazer as operações necessárias do método de Jacobi.

## 2 Questão 2

Implementar uma função Scilab resolvendo um sistema linear  $Ax = b$  usando o algoritmo iterativo de Gauss-Seidel.

### 2.1 1º algoritmo

```
1 function [xk, normadif, nk, normares]=Gauss_Seidel_1(A,b,x0,E,M,tiponorma)
2
3     LD = tril(A);
4     U = A-LD;
5     invLD = inv(LD);
6
7     Mgs=-(invLD*(U));
8     Cgs=invLD*b;
9
10
11     xk = x0;
12     normadif = E;
13     nk = 0;
14     while normadif >= E && nk<M
15         x0=xk;
16         xk=-Mgs*x0+Cgs;
17         dif = x0 - xk;
18         normadif = norm(dif,tiponorma);
19         nk = nk+1;
20     end
21
22     normares=norm(A*xk-b,tiponorma);
23
24 endfunction
25
26
27
```

As variáveis de saída e de entrada são as mesmas do item anterior, por isso não foi necessário repeti-las aqui. Como pedido no enunciado, nessa primeira implementação foi usada a função inv para calcularmos a inversa de  $L + D$ . Com isso, a matriz Mgs e o vetor Cgs foram obtidos, e conseguimos fazer as iterações. Da mesma forma que na questão 1, utilizei o while para conseguir fazer isso.

## 2.2 2º algoritmo

```
1 function [xk]=resolve(LD,x)
2     n=size(x,1)
3     xk = zeros(n,1);
4     xk(1)= x(1)/LD(1,1);
5     for i =2 : n
6         xk(i)=(x(i)-LD(i,:)*xk)/LD(i,i);
7     end
8 endfunction
9
10 function [xk, normadif, nk, normares]=Gauss_Seidel_2(A,b,x0,E,M,tiponorma)
11
12     L = tril(A);
13     U = A-L;
14
15     xk = x0;
16     normadif = E;
17     nk = 0;
18     while normadif >= E && nk<M
19         x0=xk;
20         xmedio = -(U*x0) + b;
21         xk=resolve(L,xmedio);
22         dif = x0 - xk;
23         normadif = norm(dif,tiponorma);
24         nk = nk+1;
25     end
26
27     normares=norm(b - A*xk,tiponorma);
28 endfunction
29
30
```

Agora, criamos a função que resolve sistemas em que a matriz dos coeficientes é triangular inferior, assim podemos fazer as iterações nessa função.

## 3 Questão 3

Teste as funções implementadas para resolver o sistema  $\begin{cases} x - 4y + 2z = 2 \\ 2y + 4z = 1 \\ 6x - y - 2z = 1 \end{cases}$  com o vetor  $x_0 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$

Definimos  $\text{tiponorma} = 2$ ,  $M = 100$  e  $E = 10^{-5}$  neste item. Depois disso, testei a matriz e vetor propostos nos 3 códigos que fiz. Os resultados estão a seguir:

Figura 1: console 3.1

```
--> [xk, normadif, nk, normares]=Jacobi(A,b,x0,E,M,tiponorma)
xk =

    2.103D+50
    1.852D+50
   -1.818D+50
normadif =

    3.359D+50
nk =

    100.
normares =

    1.733D+51
```

Figura 2: console 3.2

```
--> [xk, normadif, nk, normares]=Gauss_Seidel_1(A,b,x0,E,M,tiponorma)
xk =

    1.278D+68
    4.714D+68
    1.476D+68
normadif =

    3.970D+68
nk =

    100.
normares =

    2.119D+69
```

Figura 3: console 3.3

```
--> [xk, normadif, nk, normares]=Gauss_Seidel_2(A,b,x0,E,M,tiponorma)
xk =

    2.936D+67
   -3.025D+68
    2.393D+68
normadif =

    3.970D+68
nk =

    100.
normares =

    1.754D+69
```

A norma das diferenças nos aponta que em nenhum dos métodos converge, pois ela é diferente e possui valores altos. Quando conferimos o raio espectral para cada um desses métodos, notamos que o módulo do resultado é maior que 1, o que nos diz que não haverá a convergência. Agora,

faremos com que essa matriz seja diagonalmente estritamente dominante, para conferirmos se vamos chegar em outra solução.

$$A_{DD} = \begin{bmatrix} 6 & -1 & -2 \\ 1 & -4 & 2 \\ 0 & 2 & 4 \end{bmatrix} \text{ e } b_{DD} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}$$

Altere o E para  $10^{-6}$ , para obter resultados ainda mais próximos. Abaixo, o que eu encontrei com o método de Jacobi e com Gauss-Seidel:

Figura 4: console 3.4

```
--> [xk, normadif, nk, normares]=Jacobi(A,b,x0,E,M,tiponorma)
xk =

    0.2499998
   -0.2500002
    0.3750003
normadif =

    0.0000007
nk =

    20.
normares =

    0.0000021
```

Figura 5: console 3.5

```
--> [xk, normadif, nk, normares]=Gauss_Seidel_2(A,b,x0,E,M,tiponorma)
xk =

    0.25
   -0.2500000
    0.3750000
normadif =

    0.0000003
nk =

    12.
normares =

    0.0000002
```

Chegamos em um resultado! Isso aconteceu porque, como dito em um teorema comentado em aula, se A tem diagonal estritamente dominante, então isso implica que o método de Jacobi converge! A mesma ideia acontece com Gauss Seidel, que é um modelo parecido com Jacobi. Como esperado, a norma das diferenças é um número extremamente pequeno, assim como a norma do resíduo. É interessante notar também que o método de GaussSeidel chega em um resultado consideravelmente mais rápido que o método de Jacobi (12 operações contra 20), devido ao funcionamento de Gauss Seidel.

## 4 Questão 4.1

Para o sistema do exercício 3 da Lista de Exercícios 2, mostre que o método de Jacobi com  $x^{(0)} = 0$  falha em dar uma boa aproximação após 25 iterações.

$$A2 = \begin{bmatrix} 2 & -1 & -1 \\ 2 & 2 & 2 \\ -1 & -1 & 2 \end{bmatrix} \text{ e } b2 = \begin{bmatrix} -1 \\ 4 \\ 5 \end{bmatrix}$$

Coloquei esses valores em A2 e B2 e testei com o método de Jacobi. O resultado está a seguir.

Figura 6: console 4.1

```
--> [xk, normadif, nk, normares]=Jacobi(A2,b2,x0,E,M,tiponorma)
xk =

-20.827873
2.
-22.827873
normadif =

34.924597
nk =

25.
normares =

87.311491
```

Conseguimos notar que o método não convergiu. As diagonais não são estritamente dominantes, então nós não tínhamos certeza que iria convergir. Quando calculamos o raio espectral, encontramos resultado 1.11, que é maior que 1. Logo, não converge.

## 5 Questão 4.2

Use o método de Gauss-Seidel com  $x^{(0)} = 0$  para obter uma aproximação da solução do sistema linear com precisão de  $10^{-5}$  na norma-infinito.

A seguir, testei a matriz com  $E^{-5}$ . Foi possível notar, pelas 23 operações realizadas, que o método converge. xk está convergindo para (1, -1, 1), e esse resultado é encontrado quando alteramos E para um valor maior, como testei com o valor  $E^{-8}$  depois. Diferente da 4.1, que utilizamos o método de Jacobi, agora temos raio espectral igual a 0.5, que nos indica que o método converge.

Figura 7: console 4.2

```
--> [xk, normadif, nk, normares]=Gauss_Seidel_2(A,b,x0,E,M,tiponorma)
xk =

    1.0000023
    1.9999975
   -1.0000001
normadif =

    0.0000073
nk =

    23.
normares =

    0.0000069
```

## 6 Questão 5.1

Utilize o método iterativo de Gauss-Seidel para obter uma aproximação da solução do sistema linear do exercício 5 da Lista de Exercícios 2, com tolerância de  $10^{-2}$  e o máximo de 300 iterações.

Figura 8: console 5.1

```
--> [xk, normadif, nk, normares]=Gauss_Seidel_2(A,b,x0,E,M,tiponorma)
xk =

    0.8975131
   -0.8018652
    0.7015543
normadif =

    0.0064659
nk =

    13.
normares =

    0.0040412

-->
```

É possível notar que o método convergiu, de acordo com os resultados que encontramos. Para verificarmos isso, calculamos o raio espectral, que nos deu valor 0.625, que é um número dentro do que esperavamos.

## 7 Questão 5.2

O que acontece ao repetir o item a) quando o sistema é alterado para 
$$\begin{cases} x_1 - 2x_3 = 0.2 \\ -0.5x_1 + x_2 - 0.25x_3 = -1.425 \\ x_1 - 0.5x_2 + x_3 = 2 \end{cases}$$

Figura 9: console 5.2

```
--> [xk, normadif, nk, normares]=Gauss_Seidel_2(A,b,x0,E,M,tiponorma)
xk =
    2.157D+41
    1.348D+41
   -1.483D+41
normadif =
    5.085D+41
nk =
    300.
normares =
    5.162D+41
```

Agora, nessa situação, notamos que o método não convergiu. Ao calcularmos novamente o raio espectral, encontramos nesse item o resultado 1.375, que nos diz que o método não converge, pois é maior que 1.

## 8 Questão 6

Agora gere matrizes  $A_{n \times n}$  com diagonal estritamente dominante para  $n=10$ ,  $n=100$ ,  $n=1000$ ,  $n=2000$ , ... bem como vetores  $b$  com dimensões compatíveis e resolva esses sistemas  $Ax=b$  pelo Método de Gauss-Seidel, usando as duas versões implementadas no item 2. Use as funções `tic()` e `toc()` do Scilab para medir os tempos de execução e compará-los.

```
1 function [tempo]=tempoexecucao(tam)
2     b = ceil(10*rand(tam,1));
3     A = ceil(10*rand(tam,tam));
4     for j= 1 : tam
5         A(j,j)=1+sum(abs(A(j,:)));
6     end
7     x=zeros(tam,1);
8     tic();
9
10    [xk, ndif, k, nres] = Gauss_Seidel_1(A,b,x,0.000001,300,2);
11    t1 = toc();
12    tic();
13    [xk, ndif, k1, nres] = Gauss_Seidel_2(A,b,x,0.000001,300,2);
14    t2 = toc();
15    tempo =[t1,t2,k,k1];
16 endfunction
17
```

Gerei essa função para podermos calcular o tempo gasto para executar com os dois métodos, Gauss Seidel 1 e Gauss Seidel 2. A seguir, prints dos resultados, onde o 1º mostra o tempo com a função `inv` (Gauss Seidel 1) e o 2º mostra sem ela (Gauss Seidel 2), e, na frente, o número de iterações realizadas. O número de entrada mostra o tamanho da matriz quadrada.



Figura 10: console 6.1

```
--> A = tempoexecucao(100)
A =

    0.0020847    0.0179577    9.    9.

--> A = tempoexecucao(1000)
A =

    0.115101    0.325413    8.    8.

--> A = tempoexecucao(3000)
A =

    3.0613025    2.5951646    8.    8.

--> A = tempoexecucao(6000)
A =

   22.740992    7.6942623    8.    8.
```

É possível notar que, para matrizes pequenas, a função `inv` é viável e não gasta muito tempo/-memória. Entretanto, quando colocamos uma matriz 3000x3000 e posteriormente 6000x6000, o tempo de execução das duas funções é muito diferente, o que torna muito mais viável a utilização de Gauss Seidel 2. Depois disso, ainda testamos com matrizes maiores: 10.000 x 10.000 e 20.000 x 20.000:

Figura 11: console 6.2

```
--> A = tempoexecucao(10000)
A =

   91.585255    23.880435    7.    7.
```

Figura 12: console 6.3

```
--> A = tempoexecucao(20000)
A =

  744.11523    136.80405    7.    7.
```

Aqui, o tempo foi ainda maior. Na primeira tentativa, , com `tempoexecucao(10000)`, Gauss Seidel 1 levou 1 minuto e meio, enquanto Gauss Seidel 2, apenas 23 segundos. Já em `tempoexecucao(20000)`, A função com `inv` chegou a gastar mais de 12 minutos, enquanto a outra, pouco mais de 2 minutos! Além disso, também fiz o printscreen do meu gerenciador de tarefas no momento da execução de cada item, e o resultado foi um consumo muito grande da memória RAM (de 16 GB) nas duas operações, como esperado.

Figura 13: console 6.4

